第 3 章：精度与数值的艺术 (Numerical Precision)

> **"God made the integers, all else is the work of man."** —— Leopold Kronecker

在数学世界里，实数轴是连续的、无限稠密的。但在计算机的硅基世界里，**“实数”是不存在的**。

计算机只有有限的比特（0 和 1）。当我们试图用有限的比特去模拟无限的实数时，必然会付出代价——这个代价就是**精度（Precision）**。

对于 AI 工程师来说，理解这个代价至关重要。为什么 BERT 模型用 FP16 训练会比 FP32 快一倍且显存减半？为什么 LLaMA 用 BF16 而不是 FP16？为什么 `0.1 + 0.2 != 0.3`？

这一章，我们将揭开浮点数的物理面纱。

3.1 浮点数陷阱：为什么计算机算不准？

3.1.1 科学计数法的二进制版本

在 IEEE 754 标准中，一个浮点数被存储为三部分：

$$\text{Value} = (-1)^{\text{Sign}} \times (1 + \text{Mantissa}) \times 2^{\text{Exponent} - \text{Bias}}$$

- **符号位 (Sign)**：正还是负？
- **指数位 (Exponent)**：决定了数值的**范围**（数量级）。存储的是 `真实指数 + Bias`。
  - **Bias 的由来**：为了让指数能够表示负数（如 2^{-3}），IEEE 754 规定指数位采用**移码 (Offset Binary)** 表示。
  - 公式：$\text{Bias} = 2^{k-1} - 1$，其中 k 是指数位的位数。
  - 例如 FP32 有 8 位指数，$\text{Bias} = 2^{8-1} - 1 = 127$。
- **尾数位 (Mantissa)**：决定了数值的**精度**（有效数字）。

格式	总位数	符号位	指数位 (Range)	尾数位 (Precision)	Bias
FP32	32	1	8	23	127
FP16	16	1	5	10	15

格式	总位数	符号位	指数位 (Range)	尾数位 (Precision)	Bias
BF16	16	1	8	7	127

> **计算示例 1：如何从机器码反推数值？(FP16)**
>
> 假设内存中有一个 FP16： `1 | 10010 | 1000000000`
>
> 1. **符号位**： `1` $\rightarrow$ 负数。
> 2. **指数位**： `10010` (十进制 18)。
> - 真实指数 = $18 - 15(\text{Bias}) = 3$。
> 3. **尾数位**： `100...` (10位)。
> - 补上隐含的 `1.` $\rightarrow 1.1$ (二进制)。
> - $1.1_2 = 1 + 2^{-1} = 1.5$ (十进制)。
> 4. **最终计算**：
> - $\text{Value} = -1 \times 1.5 \times 2^3 = -1.5 \times 8 = -12.0$
>
> **计算示例 2：计算机如何表示 0.15625？(FP16)**
>
> 1. **科学计数法**：$0.15625 = 1.25 \times 2^{-3}$
> 2. **符号位**：正数 $\rightarrow$ `0`
> 3. **指数位**：
> - 真实指数是 -3。
> - 在 FP16 中，存储指数 = 真实指数 + Bias = $-3 + 15 = 12$。
> - 12 的二进制是 `01100` 。
> 4. **尾数位**：
> - 1.25 的二进制是 1.01。
> - 去掉隐含的整数 `1` ，剩下 `01` 。
> - 补齐 10 位： `0100000000` 。
>
> **最终机器码**： `0 | 01100 | 0100000000`

这就好比用一把尺子去测量宇宙：

- **指数**决定了尺子有多长。
- **尾数**决定了尺子上的刻度有多密。

3.1.2 浮点数的“稀疏”分布

初学者最容易忽视的是：**浮点数在数轴上的分布是不均匀的。**

- **在 0 附近**：浮点数非常稠密，精度极高。

- **在数值很大时**：浮点数变得非常稀疏，两个相邻可表示数之间的差距（Gap）会变得巨大。

为了直观理解，我们模拟了一个只有 6 bit 的微型浮点系统（Mini-Float），并画出了它能表示的所有数值：

> **Mini-Float 6-bit 定义**：
>
> - **1 bit 符号位**
> - **3 bit 指数位** (Bias = 3)
> - **2 bit 尾数位**
> - 能表示的最大值：$1.75 \times 2^{(6-3)} = 1.75 \times 8 = 14$ (注意：指数全为1时通常保留给Inf/NaN)

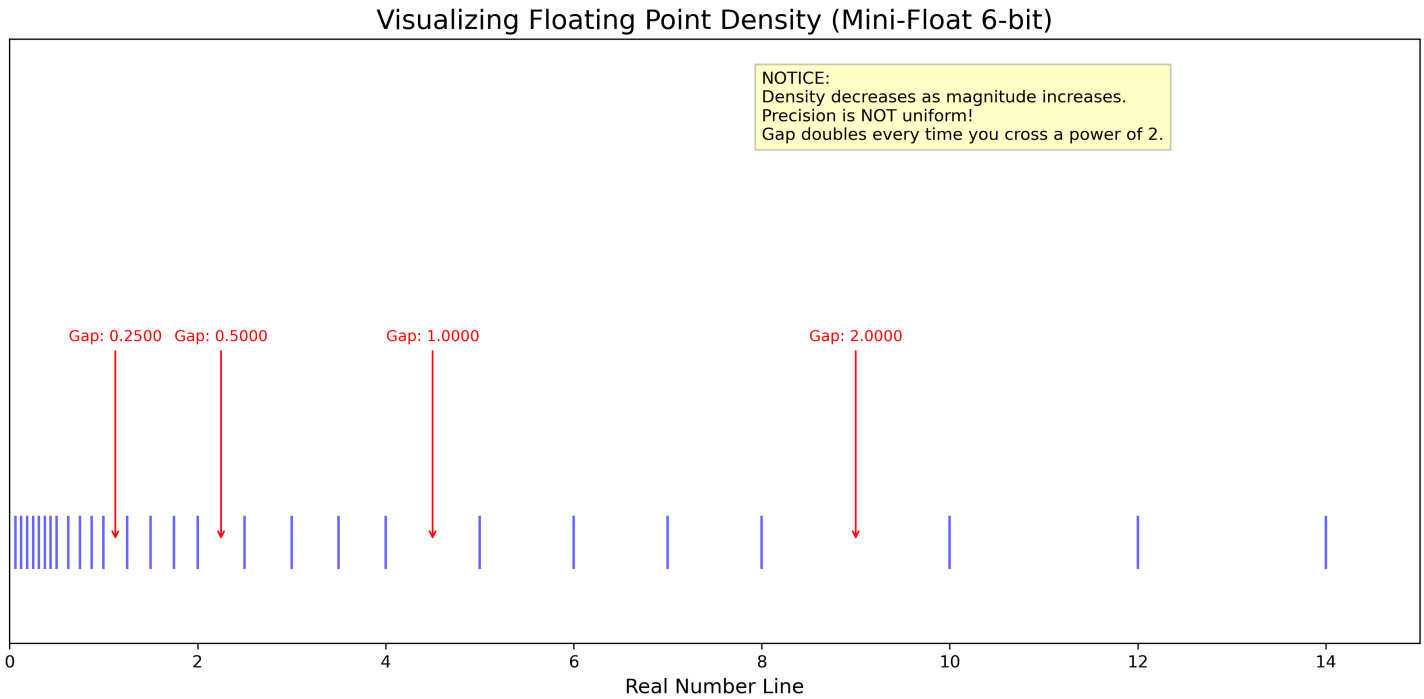

> **图解说明**：
>
> - 蓝色的竖线代表计算机能“精确表示”的数字。
> - 红色的箭头标注了相邻两个数字之间的间隙 (Gap)。
> - **关键观察**：随着数值变大（从 0.5 到 4.0），**蓝线变得越来越稀疏，间隙（Gap）成倍增加**。
> - 在 [0.25, 0.5] 区间，Gap 很小，精度很高。
> - 在 [2, 4] 区间，Gap 变大。这意味着：在这个区间内，任何计算结果如果落在了空隙里，都必须被强制“舍入”到最近的蓝线上。这就是**精度丢失**的物理来源。

数学推论：
浮点数的绝对误差（Absolute Error）与数值本身的大小成正比。也就是说，**数值越大，误差越大**。

这解释了一个经典现象：**大数吃小数**。
如果你尝试计算 `10000000.0 + 0.0000001` ，在 FP32 中结果可能还是 `10000000.0` 。因为 `0.0000001` 比

`10000000.0` 对应的 Gap 还要小，直接被舍入抹平了。

3.2 混合精度训练 (Mixed Precision)

在大模型时代，我们越来越贪婪：想要模型更大，训练更快，显存更省。
于是，工程师们开始打**精度**的主意。

3.2.1 FP32 vs FP16 vs BF16

格式	总位数	指数位 (Range)	尾数位 (Precision)	特点	适用场景
FP32 (Single)	32	8	23	**黄金标准**。范围大，精度高。	传统科学计算，模型权重的最终保存格式。
FP16 (Half)	16	5	10	**范围极窄**。容易发生上溢出 (Overflow) 或下溢出 (Underflow)。	早期 GPU 加速 (Volta/Turing)，需配合 Loss Scaling。
BF16 (Brain Float)	16	8	7	**截断版 FP32**。范围与 FP32 一样大，但精度降低。	**大模型训练主流** (Ampere/Hopper)，不需要 Loss Scaling。

3.2.2 为什么 BF16 赢了？

早期的混合精度训练（NVIDIA Volta 时代）主要使用 **FP16**。
但 FP16 有个致命缺陷：**指数位太少（只有 5 位）**。
这导致它能表示的最大数只有 65504。而在深度学习训练中，部分中间值 很容易超过这个范围，导致变为 `inf` (Infinity)，训练直接崩盘。

Google 的工程师想出了一个天才的 Hack：**BF16**。
他们直接把 FP32 的后 16 位尾数砍掉，保留前 16 位。

- **优点**：指数位保持 8 位，动态范围与 FP32 完全一致！妈妈再也不用担心我的梯度溢出了。

- **缺点**：尾数精度降低了。但在深度学习中，神经网络对**数值范围**极其敏感，而对**尾数精度**具有很强的鲁棒性（Noise Resilience）。

这就是为什么现在 LLaMA、GPT-4 等大模型全都是用 **BF16** 训练的。

3.2.3 Loss Scaling (仅限 FP16)

如果你被迫使用旧显卡（如 V100, T4, 2080Ti）训练，不支持 BF16，只能用 FP16。为了防止**下溢出 (Underflow)**（即梯度太小，变成了 0），必须使用 **Loss Scaling** 技术。

1. **Forward**: 正常计算 Loss。
2. **Scaling**: 把 Loss 乘以一个大数（如 2^{10}）。
3. **Backward**: 算出放大的梯度。
4. **Unscaling**: 在更新权重前，把梯度除以同一个大数，还原回去。

这就像是用显微镜（Scaling）把微小的梯度放大，防止它们在 FP16 的粗糙刻度尺上消失。

3.3 FP8 与量化 (Quantization)

当我们把 FP16/BF16 压榨到极致后，下一步是什么？
FP8。

在 NVIDIA H100 GPU 上，引入了 FP8 支持。

- **E4M3** (4位指数，3位尾数)：用于权重和激活值（需要一定精度）。
- **E5M2** (5位指数，2位尾数)：用于梯度（需要大动态范围）。

更进一步，在推理阶段，我们可以使用 **INT8** 甚至 **INT4** 量化。
这涉及到将连续的浮点数映射到离散的整数格点上：

$$Q = \text{round}(S \times X + Z)$$

量化不仅节省了显存（模型体积直接 /4），更重要的是：**整数运算（INT8 Tensor Core）比浮点运算快得多且能耗更低**。

总结：精度的哲学

1. **精度不是免费的**：更高的精度 = 更多的显存 + 更慢的计算。
2. **大数吃小数**：在累加操作（Accumulation）中，尽量使用高精度（FP32），即使输入是低精度（FP16）。这就是 Tensor Core 内部 `HMMA` (Half Matrix Multiply Accumulate) 指令的原理：**输入 FP16 -> 累加 FP32 -> 输出 FP16**。
3. **BF16 是首选**：如果你有 A100/H100/3090/4090，请无脑使用 BF16。

下一步

现在我们理解了数据是如何存储（内存）、如何计算（CPU/GPU）、以及数值本身的物理限制（精度）。但是，写出来的 Python 代码到底是怎么变成机器指令的？为什么 Python 这么慢？

下一章：**第 4 章：Python 的性能真相 (The Interpreter Overhead)**。