第 5 章：张量的物理视图 (The Physics of Tensors)

> **"A Tensor is a view of a Storage."**
> —— PyTorch Internals

> **动手实验**：本章配套代码 assets/tensor_internals.py 可直接运行，直观展示 Stride、Storage 地址与 Broadcasting 的物理行为。

你在 Python 中看到的 `(3, 4, 5)` 维度的张量，其实是一个美丽的谎言。

在物理内存中，根本不存在“维度”这个概念。内存是一条长长的、一维的线性磁带。无论你的张量是 3 维、4 维还是 100 维，它们在底层的物理存储（Storage）里，都只是一串连续（或不连续）的数字。

本章将带你撕开维度的面纱，通过 **Stride (步长)** 和 **Storage (存储)** 这两个物理概念，彻底理解 PyTorch/NumPy 的底层魔法。

5.1 内存布局：维度只是幻觉 (Memory Layout)

5.1.1 什么是 Stride (步长)?

想象一下，你有一个 3×4 的矩阵 A：

$$A = \begin{bmatrix} 0 & 1 & 2 & 3 \\ 4 & 5 & 6 & 7 \\ 8 & 9 & 10 & 11 \end{bmatrix}$$

在物理内存中，这 12 个数字是这样排排坐的（假设是 **Row-major / C-Contiguous**）：

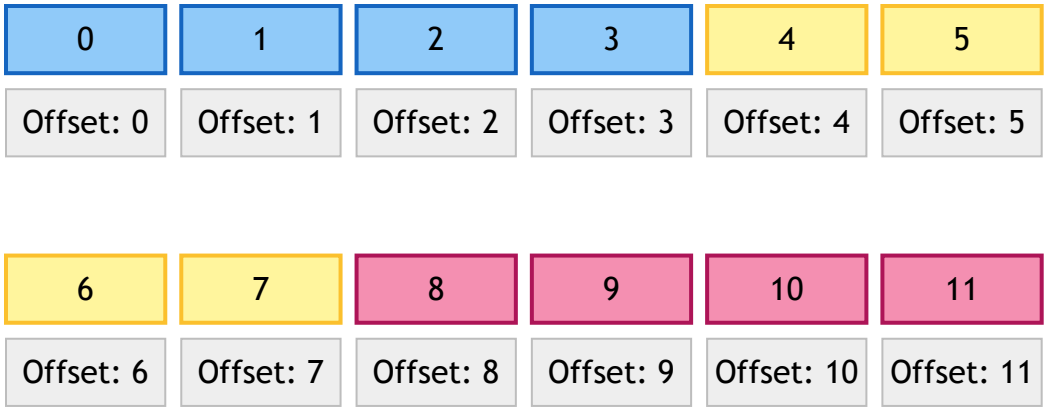

那么，当你访问 `A[1, 2]` （即数字 6）时，计算机怎么知道它在内存的哪个位置？

这就是 **Stride** 的作用。Stride 是一个数组，告诉计算机：**在某个维度上移动一步，物理内存中需要跳过多少个元素？**

对于这个 3×4 的矩阵：

1. **第 0 维 (行)**：从第 0 行跳到第 1 行（如从 0 跳到 4），内存中需要跳过 **4** 个元素（整个一行的长度）。所以 `stride[0] = 4` 。
2. **第 1 维 (列)**：从第 0 列跳到第 1 列（如从 0 跳到 1），内存中需要跳过 **1** 个元素。所以 `stride[1] = 1` 。

寻址公式：

$$\text{Offset} = \text{index}_0 \times \text{stride}_0 + \text{index}_1 \times \text{stride}_1 + \dots$$

验证一下 `A[1, 2]` ：

$$\text{Offset} = 1 \times 4 + 2 \times 1 = 6$$

确实，数字 6 就躺在物理内存的第 6 个位置（从 0 开始数）。

5.1.2 零拷贝操作：View, Transpose 与 Permute

PyTorch 中最神奇的操作莫过于 `view` 、 `transpose` 和 `permute` 。它们能在微秒级完成，即使张量有几个 G 那么大。

为什么？因为它们**根本没有复制数据**！它们只是修改了 **Stride** 和 **Shape** 这两个元数据（Metadata）。

案例：转置 (Transpose)

当我们执行 `B = A.t()` （转置）时，逻辑上的 B 变成了 4×3：

$$B = \begin{bmatrix} 0 & 4 & 8 \\ 1 & 5 & 9 \\ \cdots & \cdots & \cdots \end{bmatrix}$$

但在物理内存中，**数据纹丝不动**，还是 `0, 1, 2, 3, 4...` 。
那是怎么变的？**改 Stride！**

- `A.stride` 是 `(4, 1)`
- `B.stride` 变成了 `(1, 4)`

验证 `B[1, 0]` （即原矩阵的 `A[0, 1]` = 1）：

$$\text{Offset}_B = 1 \times \text{stride}_0 + 0 \times \text{stride}_1 = 1 \times 1 + 0 \times 4 = 1$$

物理内存第 1 个位置确实是 **1**。

陷阱：Contiguous (连续性)

虽然转置很快，但它产生了一个副作用：**内存不再连续了**。

- **行优先 (Row-major / C-Contiguous)**：在一行内移动，内存是连续的。这是 PyTorch/C 的默认格式。
- **列优先 (Col-major / F-Contiguous)**：在一列内移动，内存是连续的。这是 MATLAB/Fortran 的默认格式。

当你对一个转置后的张量执行 `view` 时，经常会报错：

```
RuntimeError: view size is not compatible with input tensor's size and stride...
```

原因： `view` 要求张量必须是 **C-Contiguous** 的，因为它假设可以通过重新计算 Stride 来映射形状。如果内存本身乱了，简单的数学变换就失效了。

解决方法： `.contiguous()` 。
这个操作会**真的复制数据**，把内存重新排列成整齐的行优先顺序。

> **为什么 Contiguous 对性能至关重要?**
>
> **CPU Cache Line**：CPU 读取内存不是一个字节一个字节读的，而是一次“抓”一块（通常 64 字节，即 16 个 float32）。
>
> - **连续内存**：当你处理 `A[0, 0]` 时，CPU 顺手把 `A[0, 1]` 到 `A[0, 15]` 都抓进了 L1 Cache。接下来的计算就是极速的。

> - **不连续内存**：如果 stride 很大（比如列优先访问行），每次访问 `A[0, 0]`，`A[0, 1]` 都需要跳跃到新的内存块，导致 **Cache Miss**，CPU 只能无奈地等待内存响应（慢 100 倍）。

> **性能启示**：
>
> 1. 尽量减少 `.contiguous()` 调用，因为它会触发内存拷贝（慢！）。
> 2. 但在将 Tensor 传给 CUDA Kernel 或 C++ 扩展前，通常必须保证它是 Contiguous 的。

5.2 广播机制：无中生有的艺术 (Broadcasting)

当你执行 `A + B` 时，如果 A 是 $(3,3)$，B 是 $(1,3)$，PyTorch 会自动把 B “复制” 3 份变成 $(3,3)$ 再相加。

这真的发生了内存复制吗？**没有**。

5.2.1 虚拟扩展 (Virtual Expansion)

广播的本质是将某一维度的 **Stride 设置为 0**。

假设 B 是 `[10, 20, 30]`，形状 `(1, 3)`。物理内存里只有这 3 个数。
`stride` 是 `(3, 1)`（或者是 `(0, 1)`，取决于实现细节，但逻辑上相当于在第 0 维移动不消耗内存偏移）。

当我们把它广播成 $(3,3)$ 时，逻辑上看是：

$$\begin{bmatrix} 10 & 20 & 30 \\ 10 & 20 & 30 \\ 10 & 20 & 30 \end{bmatrix}$$

但它的 **Stride** 变成了 `(0, 1)`！

验证访问 `B_broadcast[2, 1]`（应该是 20）：

$$\text{Offset} = 2 \times 0 + 1 \times 1 = 1$$

物理内存第 1 个位置确实是 **20**。

无论你在第 0 维怎么跳（第 1 行、第 2 行...），因为 stride 是 0，你永远在读物理内存里的同一行数据。

5.2.2 为什么要用广播?

1. **省显存**：计算 Attention Matrix 时，如果直接把 mask 矩阵物理复制成 $B \times H \times S \times S$，显存可能瞬间爆炸。广播让你免费拥有了巨大的矩阵。
2. **省带宽**：从内存读取数据的量更少了。CPU/GPU 只需要读一行数据，然后在寄存器里反复用，极大地提高了缓存命中率。

5.3 总结：从物理视角看 Tensor

操作	逻辑变化	物理数据	Stride 变化	性能
View / Reshape	改变形状	**不变**	重新计算	极快 ($O(1)$)
Transpose / Permute	交换维度	**不变**	交换顺序	极快 ($O(1)$)
Slice (切片)	取子集	**不变**	仅仅改变 Offset 和 Stride	极快 ($O(1)$)
Broadcasting	扩展维度	**不变**	某维 Stride 设为 0	极快 ($O(1)$)
Contiguous	无 (内存重排)	**复制重排**	重置为标准行优先	慢 ($O(N)$)

下一章预告：
既然我们知道了数据是如何在内存中“摆放”的，那么如何高效地把它们“喂”给 GPU 呢？第 6 章我们将深入 **数据流水线 (Data Pipeline)**，剖析 DataLoader 的多进程预取机制。

> **附：Expand vs Repeat**
>
> - `a.expand(3, 3)`：**零拷贝**。仅仅修改 Stride 为 0。推荐使用。
> - `a.repeat(1, 3)`：**深拷贝**。会在物理内存中真的把数据复制 3 份。尽量避免。